# CSD-MT — 가짜 정답 없이 하는 비지도 화장 전이 (내용·스타일 분리)

**원제** Content-Style Decoupling for Unsupervised Makeup Transfer without Generating Pseudo Ground Truth
**저자** Zhaoyang Sun, Shengwu Xiong, Yaxiong Chen, Yi Rong (Wuhan University of Technology 외) **발표** CVPR 2024 · CVF · arXiv:2405.17240 v1 (2024-05-27) · arXiv · 코드 **라이선스** CC BY-NC-SA 4.0 — 그래서 이 논문만 **전문 번역**이 따로 있습니다

> **한 줄**: "화장은 **저주파**(뭉개진 색)에 있고, 얼굴 내용은 **고주파**(윤곽·질감)에 있다"는 관찰 하나로, 기존 방법이 전부 쓰던 **가짜 정답(PGT)을 없앴다.** 6.94M 파라미터, 한 쌍에 0.017초.

---

## 무엇을 풀려 했나

화장 전이에는 **진짜 정답 사진이 없다**(같은 사람의 "이 화장을 한 사진"이 없음). 그래서 기존 방법은 전부 **가짜 정답**을 만들어 그걸 따라가게 학습했다.

- **히스토그램 맞추기**: 부위별 색 분포만 맞춤 → 화장의 **공간 정보를 다 버리고**, 원본·참조 색 차이가 크면 (아이섀도·블러셔) 망가진다
- **기하 왜곡**: 참조 얼굴을 원본 모양으로 휨 → **인공물**이 생기고 원본 내용이 사라진다
- **혼합형**(EleGANt): 둘을 섞어도 여전히 최적이 아니다

**가짜 정답이 부정확하면, 그걸 따라 배운 모델도 딱 그만큼만 된다.**

## 핵심 관찰

MT 데이터셋 500쌍으로 원본과 기존 방법들의 결과를 **저주파(가우시안으로 뭉갠 것)**와 **고주파(원본 − 뭉갠 것)**로 나눠 차이를 쟀다.

| | 저주파 차이 (MSE) | 고주파 차이 (MSE) |
|---|---|---|
| 화장 전 ↔ 후 | **약 277~289** | **약 2.9~4.6** |

**화장 전후 차이가 저주파에 몰려 있고, 고주파는 거의 안 바뀐다.** 그래서: - **저주파 = 화장 스타일** - **고주파 = 얼굴 내용**(정체성·구조)

## 어떻게

**생성기 두 부분** 1. **의미 대응 모듈**: 원본·참조를 (얼굴 분할 10종과 함께) 인코더에 넣어 픽셀 간 코사인 유사도 행렬 M을 만든다. "원본의 이 픽셀 = 참조의 저 픽셀" 2. **화장 렌더링 모듈**: 참조의 **저주파**를 M으로 원본 자리에 맞춰 옮기고, 원본의 **배경 + 고주파**와 합쳐 U-Net(SPADE로 화장 조건 주입)으로 결과를 만든다

**손실 — 가짜 정답 대신 "주파수별 일치"** - **전이 손실**: 결과의 저주파를 참조 자리로 되돌렸을 때 **참조 저주파와 같게**(화장) + 결과의 고주파가 **원본 고주파와 같게**(내용, 기울기 공간에서 비교) - 순환 손실 · 적대 손실(다중 스케일 판별기) - **자기 증강 재구성 손실**(새로 제안): 화장한 사진 하나를 비틀어(회전·자르기) 참조로 쓰고 원래 사

진을 원본으로 쓰면, 정답은 **원래 사진 자신**이다 → 자세·표정 차이에 강해진다 - **색 대조 손실**(새로 제안): 결과 얼굴 색 분포를 참조에 가깝게, 참조 색을 일부러 바꾼 가짜 4개에서는 멀게(VGG 그램 행렬 거리) → 색 충실도

## 결과

**정량** (MT 기준, 전부 MT로만 학습)

| 방법 | FID ↓ | 자기증강 PSNR/SSIM (자르기) | (회전) |
|---|---|---|---|
| BeautyGAN | 48.24 | 21.70 / 0.848 | 21.58 / 0.847 |
| PSGAN | 45.02 | 23.46 / 0.886 | 22.68 / 0.875 |
| SSAT | 38.01 | 24.01 / 0.894 | 23.93 / 0.893 |
| EleGANt | 54.06 | 25.15 / 0.885 | 24.60 / 0.875 |
| **CSD-MT** | **37.56** | **27.28 / 0.920** | **26.68 / 0.915** |

Wild-MT(자세·표정 변화 큼)에서 FID **60.82** vs 다음 SSAT 70.53 — 격차가 더 벌어진다.

**사용자 평가** (23명, 최고로 뽑힌 비율)

| | SCGAN | SpMT | SSAT | EleGANt | CSD-MT |
|---|---|---|---|---|---|
| 단순 화장 | 5.4% | 11.1% | 13.3% | 14.3% | **55.9%** |
| 복잡 화장 | 1.7% | 2.6% | 9.8% | 15.4% | **70.4%** |
| 극단 화장 | 1.1% | 1.5% | 7.4% | 13.2% | **76.7%** |

**화장이 짙을수록 격차가 커진다.**

**크기·속도** (GTX 1660Ti, 256×256 한 쌍): **6.94M · 0.017초** — 비교 방법 중 가장 작고 빠르다

**결정적 실험**: 같은 CSD-MT 구조를 PSGAN·SSAT의 **가짜 정답으로** 학습시키면, 결과가 **PSGAN·SSAT와 거의 똑같아진다.** → 성능을 좌우하는 건 구조가 아니라 **가짜 정답**이었다.

**덤으로 되는 것**: 화장 지우기 · **화장 강도 조절**(저주파를 섞는 비율) · **부위별 강도 조절**(입술만·눈만) · **피부 톤 유지** 옵션 · 여러 참조에서 부위별로 골라 섞기 · 참조 사진에 색을 칠해 **화장 편집**

## 한계

- **무늬(패턴) 화장**은 못 한다 — 무늬 경계는 고주파라 "내용"으로 분류돼 버린다
- 극단 화장의 **경계**를 정확히 못 그린다
- GAN·256×256

---

## 우리 프로젝트에 주는 것

**1. ③의 채점 방식에 대한 이론적 뒷받침이다.** 우리 채점은 부위 영역의 **평균 색 차이(Lab ΔE)**와 중앙값으로 화장을 잰다 — 사실상 "저주파"를 보고 있다. 이 논문이 **"화장 전후 차이의 대부분은 저주파에 있다"**를 500쌍으로 쟀다(MSE 약 280 vs 약 4). 발표 때 **"왜 픽셀 하나하나가 아니라 뭉갠 색으로 재나"**의 근거로 인용할 수 있다.

**2. 강도 조절이 우리 교육 흐름에 딱 맞는다.** 우리는 부위마다 **진하기**를 가르친다. 이 논문은 저주파를 섞는 비율 β 하나로 "옅게 ↔ 진하게"를, 마스크를 곱해 **입술만·눈만** 강도를 바꾼다. "이만큼 칠하면 이렇게 된다"를 보여 주는 미리보기가 원리상 간단하다.

**3. 피부 톤 유지 옵션** — 기본 동작은 참조의 **피부색까지** 옮긴다(파운데이션을 화장의 일부로 봄). 우리 룩은 피부색을 바꾸지 않으니, 쓴다면 이 옵션을 켜야 한다.

**4. 폰에 올릴 수 있는 체급이다.** 6.94M · 0.017초(노트북급 GPU). BeautyREC(0.99M)보다 크지만 품질이 낫다. FRAM 논문(1번)의 비교표에서는 **닮음은 0.585로 Stable-Makeup(0.413)보다 높지만** 화장 일치(0.434)와 구조(SSIM 0.424)가 낮게 나왔다 — 가벼운 대신 확산 모델만 못하다.

**5. 코드 공개, 라이선스는 확인 필요.** 논문(arXiv 게시본)은 CC BY-NC-SA 4.0이지만 **GitHub 코드의 라이선스는 따로 확인해야 합니다.**