# 1. FRAM — 얼굴 부위를 아는 화장 특징으로 하는 확산 모델 화장 전이

**원제** Diffusion-Based Makeup Transfer with Facial Region-Aware Makeup Features **저자** Zheng Gao 외 (Queen Mary University of London · Huawei London Research Center) **발표** CVPR 2026 · PDF

> **한 줄**: Stable-Makeup 계열의 확산 모델 화장 전이를 개선한 논문. 화장 전용으로 다시 학습시킨 CLIP으로 화장을 읽고, **눈·입·피부·코를 따로** 옮길 수 있게 만들었다. 얼굴이 원래 사람처럼 남는 정도(닮음)가 Stable-Makeup보다 크게 좋아졌다.

---

## 무엇을 풀려 했나

기존 확산 모델 화장 전이(Stable-Makeup 등)는 참조 사진의 화장을 **범용 CLIP**으로 읽어서 모델에 넣는다. 문제가 둘 있다.

1. **범용 CLIP은 화장을 잘 못 본다.** 자연 사진으로 학습해서 "화장 스타일"이라는 특징에 둔하다.
2. **화장을 통째로 넣는다.** 참조 사진의 화장 전체를 한 덩어리로 주입하니, "눈은 이 사진, 입술은 저 사진" 같은 **부위별 제어가 안 된다.**

## 어떻게

두 단계로 학습한다.

**1단계 — 화장 전용 CLIP 만들기** - 화장 데이터에는 설명 글이 없으니 **직접 합성한다.** GPT-o3에게 가벼운 것부터 짙은 것까지 화장 스타일 50개를 글로 쓰게 하고, 이미지 편집 모델 FLUX.1-Kontext-dev로 FFHQ 얼굴 사진에 그 화장을 입힌다. - 이 합성 데이터로 CLIP 시각 인코더의 마지막 층을 다시 학습한다. 목표 두 개: - **자기지도 대조 학습**: 같은 화장을 한 사진을 얼굴 모양만 비틀어(TPS·자르기·뒤집기·아핀) 두 장 만들고, 둘을 가깝게. → 얼굴 생김새는 무시하고 화장만 보게 된다 - **이미지–글 대조 학습**: 사진과 화장 설명 글을 가깝게

**2단계 — 원래 얼굴과 화장을 따로 주입** - 1단계에서 만든 합성 사진으로 **화장 전/후 짝 데이터**를 만든다. 편집 모델이 얼굴 위치를 살짝 옮기는 문제가 있어서, 랜드마크 기반 **아핀 변환으로 얼굴을 다시 맞춘다**(기존 연구는 이런 짝을 그냥 버렸다). GPT-5로 비현실적이거나 사람이 바뀐 짝을 걸러 내고, 치아·눈이 어긋난 것도 뺀다. - **화장 주입**: 학습 가능한 질의 토큰 4개(피부·눈·코·입)가 화장 CLIP에게 "이 부위 화장이 뭐냐"고 묻는다. 결과로 나온 부위별 화장 임베딩 4개를 교차 어텐션으로 확산 모델에 넣는다. - **어텐션 손실**: 각 부위 임베딩이 **실제로 그 부위를 보도록** 교차 어텐션 지도를 얼굴 분할 마스크(FaRL)에 맞춘다. 덕분에 **추론 때는 마스크 없이도** 부위별 제어가 된다. - **원래 얼굴 주입**: ControlNet Union 하나로 원본 사진 픽셀과 3D 얼굴 메시(3DDFA-V3)를 같이 넣는다. Stable-Makeup은 ControlNet을 두 개 썼다. - 확산 모델은 Stable Diffusion v2.1, LoRA로 교차 어텐션 층만 미세 조정.

**부위별 제어**: 피부는 참조 1, 눈은 참조 2, 입은 참조 3에서 임베딩을 골라 섞으면 된다.

## 결과

512×512, 세 데이터셋(MT · Wild-MT · CPM-real). **닮음(ID)**은 BlendFace 코사인 유사도, **화장 일치(CSD)**는 스타일 인코더 유사도.

| MT 데이터셋 | 화장 일치 CSD ↑ | 닮음 ID ↑ | 구조 SSIM ↑ | 배경 오차 ↓ | 미적 점수 ↑ |
|---|---|---|---|---|---|
| Stable-Makeup | 0.527 | **0.413** | 0.864 | 0.006 | 5.10 |
| SHMT | 0.498 | 0.372 | 0.811 | 0.012 | 4.86 |
| CSD-MT (GAN, 논문 4번) | 0.434 | 0.585 | 0.424 | 0.146 | 4.50 |
| **FRAM** | **0.536** | **0.587** | 0.880 | 0.002 | **5.25** |

- **Stable-Makeup 대비 닮음이 0.413 → 0.587.** 화장 일치도 조금 더 높다. 이 논문의 핵심 성과다
- 다만 CPM-real(야외 사진)에서는 닮음이 0.415 → 0.429로 **차이가 작다**
- 사용자 평가(10명, 20쌍): 최고로 뽑힌 비율 **FRAM 58.5%** · CSD-MT 20.5% · Stable-Makeup 16% · SHMT 5%
- 절제 실험: 범용 CLIP의 화장 분류 정확도 61.7% → 두 학습 목표를 다 쓰면 **88.2%**. 3D 메시만 쓰면 닮음 0.048로 무너지고, 픽셀만 쓰면 구조가 약하다 — 둘 다 필요

## 한계 (논문에 적힌 것과 읽으며 본 것)

- 논문 본문에 **속도·GPU 사양이 없다.** Stable Diffusion 기반이라 폰에서는 불가능하고, 서버에서도 샘플링 단계 수만큼 걸린다
- **코드 공개 여부가 본문에 없다**
- 사용자 평가가 10명으로 작다
- 부위가 4개(피부·눈·코·입)뿐이다 — **눈썹·볼터치·쉐딩이 따로 없다**

---

## 우리 프로젝트에 주는 것

**1. ④의 Stable-Makeup을 바꿀 후보다.** 우리가 지금 쓰는 모델과 같은 계열이고, 약점이던 닮음이 크게 좋아졌다. 우리 서버는 ArcFace 닮음이 기준 미만이면 그 룩을 "준비 중"으로 떨어뜨리는데(fallback), **이 수치대로라면 fallback이 훨씬 덜 난다.** 다만 코드가 공개됐는지부터 확인해야 한다.

**2. 부위별 제어가 우리 흐름과 맞는다.** 우리는 부위마다 한 단계씩 가르친다(눈썹 → 라이너 → 섀도우 → 입술 → 볼). "이 단계까지 칠하면 이렇게 된다"를 부위별로 보여 주는 미리보기가 원리적으로 가능해진다. 단 부위가 4개라 **우리 부위와 1:1이 아니다**(눈썹·볼터치가 없음).

**3. 데이터 만드는 방법이 우리 결정 #6과 거의 같다.** 우리는 룩 참조 사진 10장을 AI로 만들기로 했다(⑤ 담당). 이 논문이 **GPT로 화장 설명 → 이미지 편집 모델로 입히기 → 랜드마크 아핀으로 얼굴 위치 맞추기 → 걸러 내기** 순서를 이미 검증했다. 특히 "편집 모델이 얼굴 위치를 옮긴다 → 아핀으로 맞춘다"는 ⑤가 곧 부딪힐 문제다.

**4. 라이선스 주의.** 이 논문이 쓴 **FLUX.1-Kontext-dev는 비상업 라이선스로 알고 있습니다** — 확인이 필요합니다. 우리 결정 #6 생성 모델을 고를 때 같은 함정이 있습니다.