1. FRAM — 절별 한국어본

> **이 문서는 번역문이 아니라 해설입니다.** 원문 저작권이 저자·IEEE/CVF에 있어 문장을 그대로 옮기지 않고, **절마다 무슨 말을 하는지를 한국어로 풀어** 적었습니다. 수식은 뜻을 풀었고 표의 수치는 그대로 옮겼습니다. 원문: CVPR 2026 Open Access

용어 — 원본(source): 화장을 받을 얼굴 · 참조(reference): 화장을 가져올 얼굴 · 정체성(identity): 원본 사람처럼 보이는 정도 · 잡음 제거 모델(denoising model): 확산 모델의 본체(U-Net)

초록

확산 모델 화장 전이는 보통 CLIP 같은 범용 모델로 참조 화장을 읽어 조건으로 넣는다. 저자들이 보는 한계는 둘이다. 범용 모델은 화장 스타일을 잘 못 잡고, 화장을 얼굴 전체 한 덩어리로 넣어 **부위별 전이**가 안 된다.

제안하는 **FRAM**은 두 단계다. (1) GPT-o3와 글 기반 이미지 편집 모델로 설명 달린 화장 데이터를 합성해 CLIP을 **화장 전용 인코더**로 다시 학습한다. (2) 그 편집 사진으로 **화장 전/후 짝**을 만들어, 원본 정체성과 참조 화장을 확산 모델에 넣는 법을 배운다. 화장은 **학습 가능한 토큰**이 부위별로 뽑고 **어텐션 손실**로 제 부위를 보게 하며, 정체성은 **ControlNet Union**으로 원본 사진과 3D 메시를 함께 넣는다.

1. 서론

대형 글→이미지 확산 모델 이후, 원본·참조 사진을 조건으로 넣는 고품질 화장 전이가 나왔다. 그런데 이들은 자연 사진용 CLIP으로 화장을 읽어 **화장에 둔하고**, 화장을 **통째로** 넣어 부위를 골라 옮길 수 없다.

저자들의 해법: 합성 데이터로 CLIP을 화장용으로 다시 학습하고(표 3), 자기지도 얼굴 표현 학습에서 착안한 **질의 토큰**으로 부위별 화장 특징을 뽑는다. 합성은 기존 화장 데이터셋에 라벨이 없어서 택한 길이고, 자연 이미지 스타일 유사도 연구(CSD)와 달리 **화장 설명 글**도 감독 신호로 쓴다. 짝 데이터가 드물어 1단계 결과로 전/후 짝을 만들고, 부위 임베딩의 어텐션 지도를 참조 사진의 분할 마스크에 맞춰 배우므로 **추론 때는 마스크가 필요 없다.** 정체성은 Stable-Makeup이 ControlNet 두 개를 쓴 것과 달리 하나로 픽셀과 3D 구조를 함께 쓴다.

기여: FRAM 프레임워크 · 화장 CLIP · 확산 모델에서의 첫 부위별 화장 전이 시도.

2. 관련 연구

화장 전이 — GAN은 복잡한 실제 화장에 약해, 최근엔 사전학습 확산 모델에 조건을 넣는다. - Stable-Makeup: ControlNet(정체성) + 범용 CLIP(화장). FRAM은 화장용 CLIP과 부위별 주입이 다르다 - Gorgeous: 화장을 텍스트 반전으로 배워 **새 화장마다 토큰을 새로 학습**해야 한다 - SHMT: 기존 데이터로 자기지도. FRAM은 합성 짝으로 지도 학습 - MAD: 학습 없이 두 사진을 섞은 잡음으로 시작. 학습 기반보다 약하다 - 동시기 연구들도 편집으로 짝을 만들지만 **얼굴이 어긋난 결과를 버린다.** FRAM은 아핀으로 맞춰 살린다

짝 데이터 생성 — 기존 방식은 "화장 사진의 얼굴 + 원본 배경"을 마스크로 합치는데, 편집이 얼굴 위치를 옮기면 합성이 일그러진다(그림 3). TinyBeauty(메이투 앱 화장 5종), FFHQ-Makeup(기존 데이터셋 화장)은 **스타일 다양성이 좁다.** 화장을 지워서 짝을 만드는 방향도 같은 한계가 있다.

부위 찾기 — SCGAN(이미지 수준), RamGAN(특징 수준)이 있었으나 GAN 전용이다.

3. 방법

3.1 개요

확산 모델은 VAE 잠재 공간에서 돈다. 학습 때 **참조 사진**(원본의 화장본)에 잡음을 섞고 그것을 맞히게 하며, 조건으로 원본 정체성과 참조 화장 특징이 들어간다.

3.2 1단계 — 화장 CLIP 미세 조정

데이터 합성. GPT-o3가 가벼운 것부터 짙은 것까지 **화장 스타일 50개**의 설명을 쓴다. 편집 모델에 "원래 이목구비·표정·머리·배경·구도는 유지하고 이 화장을 추가하라"는 취지로 지시해 FFHQ 얼굴에 입힌다.

학습. 합성 사진 한 장을 얼굴 모양만 바꾸는 증강(TPS·자르기·뒤집기·아핀)으로 두 장 만든다 — 화장은 같고 얼굴은 다르다. - 자기지도 대조 손실(식 1): 두 장의 임베딩을 가깝게, 배치의 나머지는 멀게(InfoNCE) → 얼굴 구조를 무시하고 화장을 보게 된다 - 이미지–글 대조 손실(식 2): 사진 임베딩을 **같은 화장의 설명 글** 임베딩에 가깝게. 같은 스타일이 여럿이면 모두 양성 - 둘의 합(식 3). 사전학습 CLIP에서 **마지막 층만** 학습

3.3 2단계 — 정체성과 부위별 화장 주입

짝 합성. GPT-5로 비현실적이거나 사람·표정이 바뀐 짝을 뺀다. 얼굴 위치 어긋남은 **랜드마크 기반 아핀**으로 화장 얼굴을 원본 자리에 맞춰 해결하고, 분할 마스크 IoU로 치아·눈이 어긋난 것을 거른다.

화장 주입. 학습 가능한 **질의 토큰 N개**가 화장 CLIP 특징에 질의해 **부위별 화장 임베딩 N개**를 만든다(투영기는 InstantID 구조). 이것을 IP-Adapter처럼 이미지 프롬프트로 교차 어텐션에 넣는다. 글 프롬프트는 "a person with makeup".

어텐션 손실(식 4). 부위별 임베딩의 교차 어텐션 지도(층 평균)를 해당 부위 마스크(피부·눈·코·입)에 맞춘다. focal + dice 손실. → 각 임베딩이 제 부위를 보고, 추론 때 마스크가 필요 없다.

정체성 주입. ControlNet Union 하나에 원본 픽셀과 **3DDFA-V3로 만든 3D 메시**를 함께 넣는다.

전체 목표(식 5·6). 확산 손실 + 어텐션 손실. 교차 어텐션 층에 **LoRA**를 붙이고, LoRA·투영기·정체성 인코더를 함께 학습한다.

3.4 부위 제어

부위 임베딩을 참조마다 골라 조합하면 된다(그림 5: 피부는 참조 1, 눈은 2, 입은 3).

4. 실험

설정

N = 4(피부·눈·코·입), 화장 CLIP은 ViT-L/14. 얼굴 밖은 인페인팅으로 보호. 가능한 모든 방법을 **Stable Diffusion v2.1**로 맞춤(Stable-Makeup도 재학습). 512×512. 평가: MT · Wild-MT · CPM-real. 비교: CSD-MT(GAN), SHMT·MAD·Gorgeous·Stable-Makeup(확산). 부위별 전이는 GAN인 SCGAN과만 비교(확산 쪽엔 대상이 없음).

지표: CSD(참조와의 화장 스타일 유사도) · ID(원본과의 정체성, 화장에 강건한 BlendFace) · SSIM(구조) · L2-M(얼굴 밖 변화) · Aes(LAION 미적 점수)

표 1 — 정량 결과

방법	MT CSD ↑	ID ↑	SSIM ↑	L2-M ↓	Aes ↑	Wild CSD ↑	ID ↑	SSIM ↑	L2-M ↓	Aes ↑	CPM CSD ↑	ID ↑	SSIM ↑	L2-M ↓	Aes ↑
CSD-MT	0.434	0.585	0.424	0.146	4.50	0.428	0.585	0.430	0.124	4.41	0.418	0.522	0.410	0.128	4.41
MAD	0.328	0.535	0.805	0.003	4.26	0.401	0.541	0.808	0.002	4.18	0.317	0.491	0.788	0.003	4.18
Gorgeous	0.417	0.652	0.896	0.003	4.70	0.472	0.628	0.887	0.002	4.64	0.399	0.624	0.871	0.002	4.61
SHMT	0.498	0.372	0.811	0.012	4.86	0.516	0.411	0.820	0.010	4.78	0.417	0.408	0.793	0.013	4.64
Stable-Makeup	0.527	0.413	0.864	0.006	5.10	0.562	0.428	0.864	0.006	5.02	0.515	0.415	0.777	0.007	4.87
FRAM	**0.536**	0.587	0.880	**0.002**	**5.25**	**0.571**	0.499	0.866	**0.002**	**5.05**	**0.528**	0.429	0.797	**0.003**	**4.95**

해석: MAD·Gorgeous는 정체성은 높지만 화장을 못 옮긴다(CSD 낮음). Stable-Makeup은 화장은 강하나 정체성이 약하다. FRAM이 품질을 지키면서 균형이 가장 좋다.

정성 결과 (그림 4·6)

CSD-MT는 화장을 잡은 고품질 이미지가 어렵고, MAD는 품질·일관성이 약하고, Gorgeous는 화장을 못 잡으며, **Stable-Makeup은 정체성이 흔들리고 눈가 하이라이트 같은 세밀한 무늬를 놓친다.** 만화·그림 얼굴에서도 FRAM이 낫다.

표 2 — 사용자 평가

무작위 20쌍, 참가자 10명이 최고 하나를 고름.

CSD-MT	SHMT	Stable-Makeup	FRAM
20.5%	5%	16%	**58.5%**

절제 실험

표 3 — CLIP 학습 목표 (Acc = K=5 최근접 이웃 화장 분류 정확도, 첫 행은 범용 CLIP)

자기지도	이미지–글	Acc ↑	CSD ↑	ID ↑	SSIM ↑	L2-M ↓	Aes ↑
×	×	61.7	0.461	0.459	0.799	0.003	4.88
✓	×	80.3	0.506	0.425	0.786	0.003	4.86
×	✓	86.9	0.508	0.406	0.776	0.003	4.79
✓	✓	**88.2**	**0.528**	0.429	0.797	0.003	**4.95**

표 4 — 주입 모듈 (Pixel·3D = 정체성 인코더 입력)

LoRA	Pixel	3D	CSD ↑	ID ↑	SSIM ↑	L2-M ↓	Aes ↑
✓	✓	×	0.510	0.403	0.775	0.003	4.88
✓	×	✓	0.587	**0.048**	0.333	0.003	5.57
×	✓	✓	0.467	0.652	0.810	0.003	4.55
✓	✓	✓	0.528	0.429	0.797	0.003	4.95

3D만 쓰면 정체성이 무너지고, 픽셀은 외모·3D는 구조를 맡는다. LoRA가 없으면 화장이 약해진다(그림 7: 볼에 맨살이 보임).

표 5 — 어텐션 손실

확산	어텐션	CSD ↑	ID ↑	SSIM ↑	L2-M ↓	Aes ↑
✓	×	0.518	0.416	0.799	0.003	4.90
✓	✓	0.528	0.429	0.797	0.003	4.95

수치 차이는 작지만, 어텐션 손실이 있어야 임베딩이 실제로 피부·눈·입을 보고(그림 5) 부위별 전이가 된다.

5. 결론

화장 CLIP 미세 조정 + 전/후 짝으로 정체성·부위별 화장 주입 학습. 전체 전이와 부위별 전이 모두 기존 방법을 앞선다.

그림·표 원문 쪽수

이 한국어본에는 저작권 때문에 그림을 옮기지 않았습니다. 같은 폴더의 **원문.pdf**에서 아래 쪽을 보세요.

항목	원문 쪽
그림 1	1쪽
그림 2	3쪽
그림 3	3쪽
그림 4	7쪽
그림 5	8쪽
그림 6	8쪽
그림 7	8쪽
표 1	6쪽
표 2	6쪽
표 3	6쪽
표 4	8쪽
표 5	8쪽