BeautyREC — 절별 한국어본

> **이 문서는 번역문이 아니라 해설입니다.** 원문 저작권이 저자·CVF에 있어 문장을 옮기지 않고 **절마다 내용을 한국어로 풀어** 적었습니다. 수식은 뜻만, 표 수치는 그대로입니다. 원문: CVPRW 2023

용어 — 원본(source) · 참조(reference) · 부위(component): 피부·입술·눈 · 분할 지도(parsing map): 픽셀마다 어느 부위인지 적은 지도 · 순환 구조(cycle): 원본→변환→다시 원본으로 되돌려 내용을 지키는 CycleGAN식 학습

초록

강건(Robust)·효율(Efficient)·부위별(Component-specific) 화장 전이, **BeautyREC**을 제안한다. 전역 어텐션, 단순한 특징 연결, 잠재 공간에서의 암묵적 조작 대신 **부위별 대응**으로 참조의 화장을 원본의 같은 부위(피부·입술·눈)에 **직접** 옮긴다. 전역 전이는 트랜스포머의 장거리 의존성이 보조한다. 복잡하고 불안정한 순환 구조 대신 **내용 일관성 손실 + 내용 인코더**로 한 방향 전이를 한다. 새 데이터셋 **BeautyFace**(3,000장, 분할 라벨 포함)도 공개한다. 파라미터는 **1M**뿐이다(BeautyGAN 8.43M, PSGAN 12.62M, SCGAN 15.30M, CPM 9.24M, SSAT 10.48M).

1. 서론

화장 전이는 원본의 정체성과 화장 아닌 영역을 바꾸지 않고 참조의 화장을 옮기는 일이다. 어려움은 넷이다. 큰 어긋남은 **화장 번짐**을 부르고, 실제 짝 데이터는 구하기 거의 불가능하며, 비지도 학습 중 원본의 정체성과 배경이 쉽게 망가지고, 폰·실시간 기기에 올리려면 효율이 필요하다.

기존 방법의 결함: 원본·참조 특징을 **단순히 이어 붙이는** 방법은 어긋남에 약하고, 일부는 정체성·배경 보존을 설계에서 무시해 배경까지 망가뜨리며, 모두 복잡한 순환 구조라 메모리와 추론 시간이 크다.

BeautyREC은 부위별 대응과 **부위별 판별기**로 각 부위 화장을 같은 부위에 정교하게 옮긴다. 가장 가까운 선행 연구는 SCGAN의 부위별 스타일 인코더인데, SCGAN은 부위 특징을 잠재 공간의 **스타일 코드**로 압축해 융합 블록으로 섞으면서 **공간 정보를 버린다.** BeautyREC은 부위 화장을 명시적으로 옮기고 공간 정보를 살려 **볼 색처럼 위치가 중요한 화장**에 유리하다. 분할 지도는 이 분야에서 흔히 쓰고, 현재 분할 모델은 대부분 안정적이다. 전역 전이는 트랜스포머가 보조한다.

또 기존 방법은 모두 순환 일관성 손실을 쓰는데, 저자들은 **특징 공간에서 결과와 원본의 내용이 같도록 하는 손실 + 내용 인코더**만으로 내용을 잘 지키는 한 방향 네트워크가 된다는 것을 발견했다. 그래서 1M 파라미터가 가능했다. 한 모델로 화장 지우기·부위별 전이도 된다.

기여: ① 부위별 대응 ② 트랜스포머 기반 전역 전이 ③ 내용 일관성 손실 + 내용 인코더로 초경량 구조.

2. 관련 연구

전통 방법은 층 분해와 랜드마크 검출로 예시 화장을 옮겼다. 최근 딥러닝 방법은 거의 모두 **비지도 GAN + 순환 구조**인데, 학습이 오래 걸리고 원본 보존이 불안정하다. - BeautyGAN: 순환·지각·적대·화장 손실. 화장 손실에 분할 지도 사용 - PSGAN: 큰 자세·표정 차이에 강하도록 화장을 공간 인식 행렬 둘로 분리. 전역 어텐션이라 정확한 전이가 어렵다 - SCGAN: 부위별 스타일을 잠재 공간 코드로. 각 부위 표현이 흐릿하고, AdaIN 기반 융합이

통계만 보고 공간 스타일을 무시 - SOGAN: UV 공간에서 결합해 그림자·가림에 강건 - EleGANt: 고해상도 특징으로 색 분포 이상의 고주파 화장 보존 - SSAT: 의미 인식 트랜스포머와 약지도 의미 손실 - Nguyen 외(CPM): 색 전이 + **무늬 전이** 두 갈래. 이 논문은 무늬를 범위 밖으로 두고 CPM의 색 전이 부분만 비교

3. BeautyREC

3.1 네트워크 구조

전체 흐름(그림 2) — ① 내용 인코더가 원본의 내용 특징을 뽑는다(내용 일관성 손실 덕분에 원본의 화장에 둔감) ② 전역 스타일 인코더와 부위 스타일 인코더가 참조의 화장을 뽑는다 ③ 부위별 대응으로 입술·피부·눈 스타일을 원본의 같은 부위에 옮긴다 ④ 멀티헤드 어텐션으로 전역 의존성을 잡는다 ⑤ 이미지 복원부가 합쳐 결과를 만든다.

내용 인코더 — 실제로는 원본이 이미 화장한 경우가 많고, 그러면 결과에 **화장이 겹친다.** 기존 연구는 이를 무시하고 맨얼굴 원본을 선호했다. BeautyREC은 내용 일관성 손실로 인코더 특징이 화장에 무관하게 만든다. 효율을 위해 Conv–IN–ReLU 3층 + 잔차 블록 3개뿐이다.

스타일 인코더 — 부위용과 전역용이 같은 구조이고, 부위용은 분할 지도로 부위를 따로 뽑는다. 참조의 분할 지도를 부위별로 **이진화**(해당 부위 1, 나머지 0)해 참조 사진에 곱하면 그 부위만 남는다(식 1). 각 부위를 Conv–ReLU 3층에 따로 넣는다. 부위별 전이의 제어도 이 구조에서 나온다.

부위별 대응 — 통계 정보와 공간 정보를 함께 고려해 부위마다 정확히 옮긴다. 원본 내용 특징에 **입술 → 피부 → 눈** 순서로 하나씩 입힌다(식 2~4). 각 단계: 1. 참조 부위 스타일로 **채널 어텐션**(통계 관점의 크기 조절) 2. **공간 어텐션**(위치 관점) 3. **위치 매핑**: 원본의 해당 부위 마스크 안은 어텐션 결과로, 밖은 입력 그대로(식 5)

위치 매핑 덕분에 **화장 아닌 영역을 훼손하지 않는다.** 그림 3에서 특징이 입술 → 피부 → 눈 순으로 해당 영역만 바뀌는 게 보인다. 순서를 바꿔도 결과가 거의 같다(부록).

장거리 의존성 — 합성곱은 국소적이라 전역 화장이 부족할 수 있어 트랜스포머를 쓴다. **Query = 스타일 특징, Key·Value = 내용 특징**. 멀티헤드 어텐션(8헤드) + 사인·코사인 위치 임베딩 + 잔차 연결이 있는 2층 MLP(식 6).

이미지 복원 — 내용 인코더와 대칭 구조. 부위 전이 특징과 전역 특징을 해당 디코더 층에 이어 붙인다.

3.2 목표 함수

- **내용 일관성 손실(식 7)**: 원본과 결과를 내용 인코더 **첫 Conv–IN–ReLU 층**에 넣은 특징의 차이
- **화장 손실(식 8)**: 선행 연구처럼 부위별 **히스토그램 맞추기** 결과와의 거리(원본·참조를 바꾼 방향도)
- **지각 손실(식 9)**: 사전학습 VGG-19의 conv4(활성화 전) 특징이 원본과 비슷하게
- **적대 손실(식 10)**: 판별기 **5개** — 전역·피부·입술·왼눈·오른눈
- 전체(식 11): 내용 + 화장 + 0.005 × 지각 + 0.5 × 적대

3.3 BeautyFace 데이터셋

기존 화장 데이터셋은 다양성이 부족하고 해상도가 낮으며(보통 256×256), 몇 년 전에 모아 최신 유행이 빠져 있다. **인터넷에서 모은** 3,000장, 512×512, 최신 화장·다양한 자세·배경·표정·인종·조명. **모든 사진에 분할 라벨**(그림 4).

4. 실험

4.1 설정

PyTorch, RTX 2080Ti, Adam(학습률 1e−4 고정), 배치 1. 판별기는 국소 영역에 정확한 기울기를 주는 **U-Net 판별기**. MT(3,834장)로 학습, 테스트는 맨얼굴 100장·화장 250장 무작위. Wild·BeautyFace도 평가. 비교: SCGAN·PSGAN·CPM·SSAT(공식 모델만 사용 — 많은 방법의 코드·학습 데이터가 불분명해 재구현하지 않음).

4.2 비교

시각 비교(그림 5) — SCGAN·PSGAN·CPM은 **립스틱을 치아에 옮긴다.** SCGAN은 눈 영역에 인공물, CPM은 뚜렷한 인공물, SSAT는 화장을 잘 못 옮긴다. SCGAN·SSAT는 배경이 **빛바래고** SCGAN은 눈이 망가져 정체성까지 해친다. BeautyREC은 화장을 옮기면서 정체성과 배경을 지킨다.

표 1 — 정체성 유지 (ArcFace 코사인↑ / FID↓. MT 100쌍, Wild 100쌍, BeautyFace 300쌍)

데이터	지표	SCGAN	PSGAN	CPM	SSAT	BeautyREC
Wild	ArcFace	0.864	0.798	0.829	0.831	**0.883**
MT	ArcFace	0.857	0.735	0.849	**0.892**	0.878
BeautyFace	ArcFace	0.879	0.767	**0.919**	0.835	0.893
Wild	FID	37.87	33.51	47.91	34.96	**24.00**
MT	FID	70.59	41.30	52.97	**37.33**	38.14
BeautyFace	FID	52.29	40.31	109.06	38.33	**32.79**

주의: 이 두 지표는 **전이를 안 하고 원본을 그대로 내도 좋게 나올 수 있어** 전이 성능을 정확히 반영하지 못한다. 관례대로 참고로만 제시.

표 2 — 사용자 평가 — CPM·SSAT가 정체성 지표는 좋아도 전이 품질이 나빠서, 사람 평가로 품질을 잰다. Wild에서 원본 10·참조 10, BeautyFace에서 참조 10을 골라 20명이 순위를 매김. 기준: 참조와의 화장 유사도, 원본과의 정체성·배경 유사도, 인공물·부적절한 색 없는 사실감.

PSGAN	CPM	SCGAN	SSAT	BeautyREC
4.5%	9.0%	17.0%	22.0%	**47.5%**

표 3 — 모델 크기와 속도 (256×256 한 쌍)

방법	파라미터 (M)↓	FLOPs (G)↓	시간 (초)↓
SCGAN	15.30	1154.46	0.1272
PSGAN	12.62	38.82	0.1005
CPM	9.24	66.89	0.1424
SSAT	10.48	737.24	0.0681
BeautyREC	**0.99**	**12.59**	**0.0236**

4.3 절제 실험

부위별 대응(CSC), 장거리 의존성(LRD), 내용 일관성 손실 + 내용 인코더(L_{cont})를 하나씩 빼고 재학습.

표 4 — ArcFace ↑

	w/o L_cont	w/o CSC	w/o LRD	전체
Wild	0.855	0.866	0.859	**0.883**
MT	0.842	0.838	0.861	**0.878**

- **강건성(그림 6)**: 원본이 **화장을 했든 안 했든 같은 결과**가 나온다 — 내용 인코더와 내용 일관성 손실 덕분
- **CSC 효과(그림 7)**: 흔히 쓰는 전역 어텐션(채널·공간 어텐션으로 원본 특징을 전역 변조)으로 바꾸면 **치아 영역 화장이 모호**해지고 눈 화장을 잘 못 옮긴다
- **LRD 효과(그림 8)**: 빼면 전역 화장 전이가 나빠진다
- **L_cont 효과(그림 9)**: 같은 원본의 맨얼굴·화장 버전을 넣었을 때 내용 인코더 특징이 **화장과 무관하게 같다**

5. 결론

부위별 전이 + 전역 전이 + 내용 일관성 손실로 강건성·효율·내용 보존의 한계를 넘었다. 경량 구조와 강건한 성능으로 실제 응용에 적합하고, 새 데이터셋도 기여한다.

그림·표 원문 쪽수

이 한국어본에는 저작권 때문에 그림을 옮기지 않았습니다. 같은 폴더의 **원문.pdf**에서 아래 쪽을 보세요.

항목	원문 쪽
그림 1	2쪽
그림 2	4쪽
그림 3	6쪽
그림 4	6쪽
그림 5	7쪽
그림 6	8쪽
그림 7	8쪽
그림 8	8쪽
그림 9	8쪽
표 1	6쪽
표 2	7쪽
표 3	7쪽
표 4	8쪽