# 2. FAT — 절별 한국어본

> **이 문서는 번역문이 아니라 해설입니다.** 원문 저작권이 저자·CVF에 있어 문장을 옮기지 않고 **절마다 내용을 한국어로 풀어** 적었습니다. 수식은 뜻만, 표 수치는 그대로입니다. 원문: WACV 2022

**용어** — 원본(source) · 참조(reference) · TPS(Thin Plate Spline, 얇은 판 스플라인: 제어점 몇 개로 이미지를 부드럽게 휘는 변형) · 가짜 정답(pseudo ground truth, PGT)

---

## 초록

화장 전이는 참조의 화장을 원본에 옮기되 원본의 정체성을 지키는 일이다. 기존 방법은 사실적인 얼굴은 만들지만 **색 정확도와 공간 변형**이 약하다. 저자들은 NLP 트랜스포머에서 착안한 **FAT**로 두 얼굴의 의미적 대응을 모델링해 속성을 정밀하게 추정·전이하고, TPS를 붙인 **Spatial FAT**로 색·질감에 더해 **기하학적 속성(모양)**까지 옮기는 첫 방법을 만든다. 장점: 색 충실도, 부위 모양 변형, 자세·그림자 변화에 대한 강건성, 고해상도 생성.

## 1. 서론

참조는 색·질감·명암 같은 화장 속성을 가진다. 목표는 그 속성을 원본에 정확히 옮기면서 원본 정체성을 지키는 것이다. 기존 방법(BeautyGAN, PSGAN)은 넓은 색 범위·임의 자세·부분 가림에서도 대체로 잘 되지만, **높은 기준**에서는 부족하다 — 입술 색이 참조와 다르고 눈썹 모양이 그대로다(그림 1).

FAT는 트랜스포머의 핵심 아이디어로 원본·참조의 의미 대응을 적응적으로 모델링하고 어텐션으로 원하는 속성을 정확히 만든다. 이 틀 안에 공간 변형을 자연스럽게 넣은 **Spatial FAT**는 색과 모양을 함께 옮기는 첫 방법이다. 기여: 색 충실도·모양 변형을 새 수준으로 끌어올린 FATs, 학습용 가짜 정답 생성 전략과 고해상도 후처리, 나이 전이 같은 다른 얼굴 속성 전이로의 일반화.

## 2. 관련 연구

**스타일 전이와 화장 전이** — 이미지 스타일 전이는 가까운 분야지만 "원본의 입술은 참조의 입술에 대응해야 한다" 같은 엄격한 의미 대응을 고려하지 않아 화장 전이에 바로 못 쓴다. 화장 전용으로는 LADN(손으로 설계한 국소 판별기), BeautyGAN과 후속(부위별 히스토그램 맞추기로 가짜 정답), PairedCycleGAN(참조를 휘어 섞은 가짜 결과로 지도), PSGAN(화장을 변조 행렬로 분리해 명암 조절·강건 전이)이 있다.

**GAN 속 트랜스포머** — 트랜스포머는 한 위치의 응답을 모든 위치의 가중합으로 계산하는 자기 어텐션이다. 저자들은 이를 **자기 어텐션이 아니라 두 얼굴 사이의 상호 대응**으로 바꿔 쓴다.

## 3. 화장 전이 개관

**3.1 정식화** — 화장 전이는 원본 x와 참조 y로 결과 z를 만드는 사상 G. 핵심은 두 함수다. **추정 함수 E**가 참조에서 속성을 뽑고, **변환 함수 Γ**가 그 속성을 원본에 입힌다(식 1). 보통 고차원 특징에서 수행한다. 기존 방법은 E·Γ를 여러 방식으로 골랐지만(LADN: MLP·연결, PSGAN: 합성곱·선형) **모두 색 공간 변환만** 다뤘다. FAT는 공간 변환과 호환되게 설계됐다.

**3.2 GAN 학습** — 같은 사람의 화장 전/후 사진을 모으기 어려워, CycleGAN식 **짝 없는 학습**이 표준이다. 생성기 손실 = 적대 손실 + 순환 일관성 손실(원본→화장→다시 원본이 되게) + 지각 손실(VGG 특징이 원본과 비슷하게)(식 2·3). 원본·참조 역할을 바꿔 대칭으로도 계산한다.

**3.3 가짜 정답을 쓴 화장 손실** — 사실적인 얼굴만으론 부족하고 참조 화장을 재현해야 하므로, **가짜 정답과의 거리**를 추가 감독으로 쓴다(식 4). 가짜 정답 만드는 법은 두 계열이다. - **블렌딩**: 참조를 휘어 원본에 섞음. 정렬이 맞으면 색·맥락을 잘 살리지만 **어긋남에 민감** - **히스토그램 맞추기**: 원본의 색 분포를 참조에 맞춤. 자세·표정 차이엔 강하지만 공간 분포를 잃어 **그림자·극단 색에 약함**

또 기존 방법은 "원본→참조" 변환을 보여 주는 가짜 정답을 쓰는데, 그 변환이 부정확해 결과도 최적이 아니다. 저자들은 **참조 얼굴의 자세·방향을 원본에 맞추는** 새 방식으로 색이 정확한 가짜 정답을 만든다.

## 4. 방법

인코더–디코더 구조를 기본으로(그림 4), FAT는 색 변환, Spatial FAT는 공간 변환을 맡는다.

**4.1 FAT** — 기존 어텐션 모듈은 부위별 유사도에 의존해 공간 모델링이 없고 느리다(PSGAN은 부위별 순차 계산 때문에 기반 모델보다 10배 느림). - 원본·참조 특징을 학습 가능한 가중치로 투영하고 내적·스케일·소프트맥스로 **어텐션 행렬**을 만든다(식 5) - 눈·입술 같은 k개 부위의 어텐션을 **병렬로** 계산해 이어 붙인다(식 6) - 참조에서 합성곱으로 뽑은 속성 γ_y에 어텐션을 곱해, 원본의 공간 배치에 맞는 γ_x를 얻는다(식 7). 속성은 한 줄 값이 아닌 **고차원 표현**이라 정보가 풍부하다 - 색 변환 Γ_c는 원본 특징에 γ_x를 **선형 변환**으로 적용(식 8)

**4.2 Spatial FAT** — FAT는 선형 변환이라 모양을 못 바꾼다. 공간 변환 네트워크(STN)에서 착안해 **TPS 변형을 예측**한다. TPS는 원래 공간의 제어점 K개와 목표 공간의 제어점 K개로 정의되며, 아핀보다 유연하면서 전체 왜곡은 작다. STN과 달리 **저해상도 특징**에서 예측한다. 참조 특징을 먼저 일반 FAT로 원본에 정렬하고(입력 순서를 뒤집어), 다운샘플된 특징 맵의 각 픽셀을 제어점(K = h × w)으로 삼아, 합성곱 + tanh로 [−1, 1] 범위의 목표 제어점을 예측한다. 그 격자로 특징을 휜다.

**4.3 랜드마크 임베딩과 얼굴 분할** — 트랜스포머의 위치 임베딩 대신 **각 픽셀에서 N개 랜드마크까지의 거리 벡터**를 쓴다(식 9, 정규화). PSGAN처럼 얼굴 분할로 특정 부위만 제어할 수 있어, Spatial FAT의 격자를 마스크로 가리면 원하는 부위만 휜다. 부분 화장도 원리상 된다.

**4.4 가짜 정답 생성** — TPS 기반으로 색 정답과 모양 정답을 따로 만든다(그림 6). - **색 정답**: 참조를 TPS로 휘어 원본 얼굴에 맞춘다. 거친 랜드마크로 얼굴 전체를 맞춘 뒤, 입술·눈썹·눈을 분할 마스크와 함께 따로 휘어 붙인다. 랜드마크 정밀도 한계로 완벽히 정렬되진 않지만 이 방식을 택한 이유는 둘 — GAN 손실이 품질은 지켜 주지만 변환 정확도는 보장하지 않으니 정확한 신호가 필요하고, 참조에서 만든 정답은 세부 속성을 보존해 더 넓은 상황에 쓸 수 있다 - **모양 정답**: 참조 부위의 **모양**은 옮기되 **위치**는 원본에 둔다(예: 참조의 일자 눈썹을 원본의 초승달 눈썹 자리에). 두 부위를 둘러싼 점 집합 P·Q 사이 거리를 최소화하는 평행 이동 Δ_Q를 구하면 **두 점 집합의 평균 차이**가 된다(식 10). 이 정답은 Spatial FAT 전용이다

## 5. 실험

MT 데이터셋(3,834장, 화장 2,719장)으로 학습, PSGAN의 M-Wild로도 평가.

**5.1 구현** — 어텐션 수 k = 2, 학습률 2e−4, Adam, 50 에폭. 256×256 얼굴로 실험하고 고해상도는 후처리로. PyTorch.

**5.2 일반 비교 (그림 7)** — DIA, CycleGAN, PairedCycleGAN, BeautyGlow, LADN, PSGAN과 비교 (BeautyGlow·PairedCycleGAN은 코드 미공개라 논문 그림을 잘라 씀). 대부분 정체성은 지키지만, DIA는 입술·눈썹 색은 좋으나 얼굴색이 부자연스럽고 아이섀도가 빠진다. BeautyGlow·PSGAN은 아이섀도는 옮기지만 색이 부정확하다. FAT는 색을 정확히 옮기며 원본의 조명도 지킨다. 또 기존 방법은 모두 **눈썹 모양을 무시**하는데 FAT는 공간 속성도 옮긴다.

**표 1 — 기능 비교**

| 방법 | 색 | 질감 | 모양 | 강건성 |
|---|---|---|---|---|
| BeautyGAN | ✓ | × | × | × |
| PairedCycleGAN | ✓ | × | × | × |
| BeautyGlow | ✓ | × | × | × |
| LADN | ✓ | ✓ | × | × |
| PSGAN | ✓ | × | × | ✓ |
| **FAT** | ✓ | ✓ | ✓ | ✓ |

**5.3 정량 비교** - **맹검 평가**: 코드가 공개된 BeautyGAN·LADN·PSGAN과 비교. PSGAN·FAT가 MT로 학습해서 공정성을 위해 M-Wild에서 비복원 추출로 200쌍. 자원자 10명이 결과를 무작위 순서로 보고 (1) 진짜 화장 얼굴과 구별하기 어려운 정도 (2) 참조와 같은 화장으로 보이는 정도로 순위를 매김. Spatial FAT는 모양이 바뀌어 티가 나므로 FAT로 비교. LADN은 학습 데이터와 차이가 커 약했고, **FAT가 1위를 가장 많이** 받음(그림 8) - **효율**:

| 방법 | CPU (초) | GPU (ms) | 어텐션 |
|---|---|---|---|
| BeautyGAN | 1.15 | 9.3 | × |
| LADN | 4.64 | 75.9 | × |
| PSGAN | 3.02 | 146.6 | ✓ |
| FAT | 1.93 | 22.0 | ✓ |
| Spatial FAT | 2.16 | 26.4 | ✓ |

PSGAN은 재구현판이며 원본보다 훨씬 빠른데도, 병렬 어텐션 덕분에 **FAT가 5배 넘게 빠르다.**

**5.4 고해상도** — 화장 전이는 보통 저해상도(PSGAN 256, LADN 361)에서 돈다. 계산량이 제곱으로 늘어서 FAT도 256을 쓰지만, **피라미드 복원**으로 잃은 고주파를 되살린다. 고해상도 원본에서 저해상도를 다시 보간해 뺀 차이 Δ를 결과에 더한다(식 11). 1200×900 원본 예시(그림 9)에서, 1K 해상도 얼굴까지는 자연스럽다.

## 6. 절제와 일반화

**정적 어텐션 vs FAT** — PSGAN식 정적 어텐션은 학습 파라미터가 없고 랜드마크 임베딩에 주로 의존하며, 시각 특징은 작은 계수(ω = 0.01)로 희석한다(식 12). FAT는 **시각 특징을 충분히 쓰고** 랜드마크는 보조다. 그림 10에서 FAT의 어텐션이 더 집중되고, 정적 어텐션은 위치가 표류한다.

**Spatial FAT 없이 모양 전이** — 모양 정답으로 FAT만 학습하면, 선형 변환이라 원리상 모양을 못 바꾼다(그림 11). Spatial FAT는 모양도 바꾸고, 추가 정렬 덕분에 **색 재현도 더 낫다.**

**나이 전이로 일반화** — 참조가 목표 나이를 보여 주는 "나이 전이"로 실험. CelebAMask-HQ를 젊은 얼굴, HRFAE로 만든 얼굴을 노인 얼굴로 학습. PSGAN은 눈·눈썹 주변 색만 옮기고 나이를 드러내는 세부를 놓치지만, Spatial FAT는 **주름과 피부결**까지 옮긴다(그림 12).

## 7. 결론

적응형 어텐션으로 얼굴 속성을 정밀하게 뽑아 입히는 FAT와, TPS로 모양까지 옮기는 Spatial FAT를 제안했다. 정밀한 속성 재현, 고해상도 생성, 경쟁력 있는 효율을 보였고, 나이 전이 실험으로 범용성도 확인했다.

---

## 그림·표 원문 쪽수

이 한국어본에는 저작권 때문에 그림을 옮기지 않았습니다. 같은 폴더의 **원문.pdf**에서 아래 쪽을 보세요.

| 항목 | 원문 쪽 |
|---|---|
| 그림 1 | 2쪽 |
| 그림 2 | 2쪽 |
| 그림 3 | 3쪽 |
| 그림 4 | 4쪽 |
| 그림 5 | 4쪽 |
| 그림 6 | 5쪽 |
| 그림 7 | 6쪽 |
| 그림 8 | 7쪽 |
| 그림 9 | 7쪽 |
| 그림 10 | 8쪽 |
| 그림 11 | 8쪽 |
| 그림 12 | 8쪽 |
| 표 1 | 6쪽 |
| 표 2 | 7쪽 |