예시와 규칙으로 이끄는 화장 추천 — 절별 해설

> **이 문서는 번역문이 아니라 해설입니다.** 원문은 AAAI 저작권(All rights reserved)이라 문장을 옮기지 않고, **절마다 무엇을 말하는지만 제 말로 풀어** 적었습니다. 표의 수치는 사실이라 그대로 옮겼습니다. 원문은 같은 폴더의 `원문.pdf`(7쪽)입니다.

초록 — 무엇을 했나

완전 자동 화장 추천 시스템을 세 단계로 만들었다. ① 화장과 관련된 얼굴 특징을 구조화된 코드로 분류한다. ② 그 코드를 넣으면, **전문가 화장 전후 사진**과 **아티스트의 지식**을 함께 학습한 신경망이 부위별 화장을 추천한다. ③ 추천한 화장을 얼굴에 자동으로 합성해 보여 준다. 이를 위해 전후 화장 데이터셋을 새로 모아 손으로 라벨을 달았고, 아티스트의 지식은 규칙 시스템으로 옮겼다.

1. 서론 — 왜 필요한가

화장하는 사람이 부딪히는 질문은 "어떤 스타일을 할까"와 "하면 어떻게 보일까"다. 기존 도구는 사용자가 단계마다 손으로 조작해야 했고, 자동화한 연구도 한 얼굴의 화장을 다른 얼굴로 **통째로 옮기는** 수준이었다.

선행 추천 연구의 문제: - 56명의 3D 데이터로 가장 닮은 얼굴을 찾아 그 화장을 옮긴 연구 → 표본이 작아 일반화가 의심스럽다 - 얼굴 특징과 화장 스타일의 관계를 학습한 연구 → **화장 전 사진이 없어서** 실제 피부색·눈 모양을 뽑기 어렵고, 유행이 바뀌면 갱신하기 어렵다 - 딥 특징으로 닮은 얼굴을 찾는 연구 → 얼굴 특징과 규칙을 고려하지 않는다

또 **규칙과 데이터를 함께 써서 신경망을 학습**하는 연구 흐름(신경–기호 통합)이 있었고, 저자들은 이를 화장 추천에 가져왔다.

2. 데이터셋

- **961명**의 여성, 각자 **맨얼굴 한 장 + 전문가 화장 한 장**. 백인 224 · 아시아인 187 · 아프리카계 300 · 히스패닉 250. 정면, 가림 없음
- 얼굴 특징의 종류(표 1)와 화장 요소의 종류(표 2)는 **메이크업 아티스트 인터뷰로 정했다**

표 1 — 얼굴 특징

특징	분류
피부색	밝음, 흰 편, 중간, 어두움
얼굴형	계란형, 각진형, 둥근형
눈 모양	외꺼풀, 올라간 눈, 처진 눈, 덮인 눈(hooded), 둥근 눈, 아몬드형
입술 모양	얇음, 보통, 두꺼움
눈 색	초록, 헤이즐, 파랑, 갈색, 검정
인종	아프리카계, 아시아인, 백인, 히스패닉

표 2 — 화장 요소

요소	분류
파운데이션 색 / 강도	밝음·흰 편·중간·어두움 / 옅게·짙게
블러셔 모양 / 색 / 강도	계란·각진·둥근 / 8색 / 옅게·짙게
립스틱 색	핑크, 레드, 오렌지, 퍼플, 누드
립라이너	있음, 없음
아이섀도 스타일	컷 크리즈, 그라데이션, 스모키, 캣아이, 헤일로, 내추럴
아이섀도 색	브라운, 크림, 블루, 웜, 스모키
아이라이너	옅게, 짙게, 날개형(winged)

3. 추천 모델

구조 — 얼굴 특징 코드를 입력으로 받아 화장 요소 8개를 한꺼번에 내놓는 다층 신경망(은닉층 3개 × 100개, 시그모이드).

오차를 재는 법 — 화장은 정답이 하나가 아니고, 틀려도 "조금 틀림"과 "많이 틀림"이 있다. 그래서 - 색 요소는 **Lab 색공간 거리(ΔE)**로 잰다 - 모양 요소(아이섀도·라이너·블러셔 스타일)는 **두 스타일이 얼마나 다른지를 전문가가 미리 정한 값**으로 잰다

두 가지 지식 — 같은 구조의 신경망 두 개를 동시에 학습한다. - **예시 신경망**: 데이터셋의 전문가 화장 라벨로 학습 - **규칙 신경망**: 아티스트 인터뷰로 만든 규칙 시스템(추론 엔진)의 답으로 학습. 규칙 예시 — 피부색이 중간이면 파운데이션도 중간 톤 / 피부색이 중간이고 입술이 얇으면 빨간 립스틱과 립라이너 - 두 쪽의 비중은 β로 조절한다(실험에서 0.1)

조합 항 — 아이섀도 색과 립스틱 색처럼 **함께 어울려야 하는 요소**가 따로 놀지 않게, 데이터에서 배운 조합 확률과 어긋나면 벌점을 준다.

4. 자동 합성

부위마다 두 단계로 입힌다. **어디에**(마스크)와 **어떤 색으로**(섞기).

- **마스크**
- 파운데이션·립스틱: 얼굴 점으로 영역 모양을 **그대로** 따 온다
- 아이섀도·블러셔·아이라이너: 스타일별 **템플릿**을 만들어 두고, 얼굴 점과 템플릿의 대응점을 맞춰 **TPS로 휘어** 사용자 얼굴에 붙인다
- **섞기**
- 립스틱·파운데이션: 원래 사진의 명암을 살리는 **소프트 라이트**
- 립라이너·속눈썹: 색을 진하게 올리는 **알파 합성**
- 아이섀도·블러셔: 두 방식을 차례로 써서, 효과는 뚜렷하게 하고 명암은 유지

5. 실험

얼굴 특징 분류

Face++로 얼굴 점 83개를 잡고, 특징마다 다른 영역(얼굴 전체 / 눈 / 눈동자 / 입술)을 잘라 색·질감 특징을 뽑은 뒤 SVM으로 분류했다. 맨얼굴 900장, 10겹 교차 검증.

특징 (분류 수)	쓴 영역	특징값	정확도
피부색 (4)	얼굴 전체	RGB 히스토그램, HOG	87.20%
얼굴형 (3)	얼굴 전체	HOG	89.95%
눈 모양 (6)	눈	HOG, LBP	**61.05%**
입술 모양 (3)	입술	HOG, LBP	79.41%
눈 색 (5)	눈동자	RGB 히스토그램	81.00%
인종 (4)	얼굴 전체	RGB 히스토그램, LBP	87.42%

저자들은 눈 모양이 6가지라 **사람에게도 어려운 과제**라고 설명한다.

통계 평가

961쌍을 학습 80% · 검증 10% · 시험 10%로 나눴다. 학습 때는 라벨된 얼굴 특징을, 시험 때는 **자동 분류한** 특징을 넣었다. 비교 대상은 닮은 얼굴을 찾아 그 화장을 가져오는 두 방법(고유 특징 / 딥 특징)과, 규칙만 / 예시만 쓴 모델이다.

표 4 — 화장 요소별 오차 (낮을수록 좋음)

요소 (분류 수)	고유 특징	규칙만	예시만	딥 특징	예시 + 규칙
파운데이션 (4)	0.37	0.55	0.42	0.23	**0.10**
립스틱 색 (5)	0.50	0.62	0.45	0.47	**0.31**
립라이너 (2)	0.40	0.32	0.23	0.35	**0.20**
블러셔 모양 (3)	0.27	0.02	0.02	0.19	**0.01**
블러셔 색 (8)	0.55	0.52	0.47	0.56	**0.34**
아이섀도 스타일 (6)	0.53	0.65	0.57	0.60	**0.32**
아이섀도 색 (5)	0.70	0.59	0.45	0.67	**0.36**
아이라이너 (3)	0.37	0.48	0.39	0.32	**0.27**
평균	0.46	0.43	0.38	0.32	**0.24**

요점: 예시와 규칙을 **섞은 모델이 모든 요소에서 가장 낮았다.** 얼굴 특징과 강하게 묶인 요소(파운데이션 톤, 립라이너, 블러셔 모양)는 오차가 작고, 좋은 답이 여럿일 수 있는 요소(립스틱 색, 아이섀도 색)는 컸다.

구조 비교

조합 항을 빼면 모든 요소의 오차가 늘었다. 요소마다 신경망을 따로 두는 방식(8개)과 비교하면, 하나의 신경망에서 8개를 함께 내는 방식이 **오차가 낮고(0.24 대 0.31) 파라미터는 88% 적었다.** 조합을 함께 배울 수 있기 때문이다.

사람 평가

- **실험 1**: 맨얼굴 20장에 추천 화장을 합성해, 남녀 각 10명(여러 문화권)에게 5단계(매우 나쁨 ~ 매우 좋음)로 평가받았다. 가장 많은 답은 **"괜찮음"**이었고, 좋음 쪽이 나쁨 쪽보다 많았다
- **실험 2**: 같은 사람들에게 맨얼굴·전문가 화장·추천 화장을 함께 보여 주고 두 화장을 비교하게 했다. **"비슷함"**이 가장 많았고, "더 나음" 쪽이 "더 나쁨" 쪽보다 많았다

합성 비교

온라인 가상 화장 서비스 두 곳(TAAZ, DailyMakeover)과 비교했다. 한 곳은 눈썹을 다룰 수 없고 속눈썹이 부자연스러웠고, 다른 곳은 강도 조절이 제한적이고 입술 모양 인식이 부정확했다. 이 논문의 합성은 **완전 자동**인데도 더 정확했다고 주장한다. 부위마다 섞는 방식을 달리한 덕분이라고 본다.

6. 결론과 향후 과제

예시와 규칙을 함께 학습한 신경망으로, 자동 분류한 얼굴 특징에 **어울리는 조합의** 화장을 추천하고 합성할 수 있음을 보였다. 향후 과제로 데이터셋 확대, 새 유행 반영, 헤어·액세서리 추천, 합성 템플릿과 색의 확장을 든다.

그림·표 원문 쪽수

항목	원문 쪽
그림 1 (전체 구조)	2쪽
표 1 (얼굴 특징)	2쪽
그림 2 (데이터셋 예시)	2쪽
표 2 (화장 요소)	3쪽
그림 3 (부위 영역과 마스크)	4쪽
표 3 (특징 분류 정확도)	5쪽
표 4 (요소별 오차)	5쪽
표 5 (구조 비교)	6쪽
그림 4·5 (사람 평가, 합성 비교)	6쪽

(쪽수는 원문 PDF의 1~7쪽 기준입니다. 학회 논문집 쪽수로는 941~947쪽입니다.)